

A Scalable Quantum Non-local Neural Network for Image Classification

Sparsh Gupta, Debanjan Konar, Vaneet Aggarwal
Implemented by: Matteo Piras

June 11, 2025

Abstract

Questo paper presenta una **rete neurale non locale ibrida quantistico-classica scalabile**, denominata **Quantum Non-Local Neural Network (QNL-Net)**, progettata per **migliorare il riconoscimento di pattern nella classificazione di immagini**. La QNL-Net mira a superare le limitazioni delle operazioni non locali classiche, che soffrono di una complessità quadratica in termini di tempo e memoria, sfruttando il parallelismo quantistico e l'entanglement per elaborare in modo efficiente le dipendenze a lungo raggio. Il modello proposto combina tecniche classiche di riduzione della dimensionalità (CNN o PCA) con circuiti quantistici variationali addestrabili (VQC). La rete dimostra **prestazioni all'avanguardia**, in particolare nella variante CNN-QNL-Net, nella **classificazione binaria** sui dataset MNIST e CIFAR-10, **utilizzando un numero significativamente inferiore di qubit** rispetto ai classificatori quantistici di riferimento.

In aggiunta al modello proposto nel paper, la mia implementazione prevede anche un'estensione alla **classificazione multiclasse** con 4 classi.

1 Introduction

La computer vision, una componente fondamentale dell'Intelligenza Artificiale (AI), comprende varie applicazioni come la guida autonoma, l'imaging medico e la sanità. La classificazione di immagini è un com-

pito cruciale che mira ad assegnare etichette alle immagini basate sul loro contenuto visivo.

Le **Convolutional Neural Networks (CNN)** hanno avanzato significativamente la classificazione di immagini, raggiungendo prestazioni elevate su dataset come ImageNet. Tuttavia, le CNN sono **ristrette dai loro campi percettivi locali**, limitando la loro capacità di catturare informazioni contestuali estese e **dipendenze a lungo raggio** nelle immagini.

Per affrontare queste limitazioni, sono state introdotte le **reti neurali non locali (NL-Net)**, che incorporano operazioni non locali che calcolano risposte aggregando caratteristiche da *tutte* le posizioni nell'input. Questo consente una **cattura efficiente delle dipendenze a lungo raggio**.

Tuttavia, le operazioni non locali classiche richiedono il calcolo di relazioni a coppie tra tutti gli elementi di un set di caratteristiche, il che porta a una **complessità quadratica in termini di tempo e memoria**. Questo rende **difficile la scalabilità** delle reti neurali non locali per problemi su larga scala.

2 La Rete Neurale Quantistica Non Locale (QNL-Net)

In questo studio, viene introdotta una nuova **Quantum Non-local Neural Network (QNL-Net)**. Questa rete **fonde i principi del QC con il meccanismo delle reti neurali non locali** per affrontare

le operazioni non locali a coppie.

La QNL-Net proposta si basa sulle **caratteristiche intrinseche dell'entanglement quantistico** per implementare operazioni non locali. Stabilisce correlazioni non locali attraverso **caratteristiche potenziate quantisticamente**, emulando le operazioni non locali classiche mentre sfrutta l'entanglement quantistico per migliorare le prestazioni e le capacità del modello. Sfrutta il **parallelismo quantistico** per consentire l'elaborazione simultanea di un gran numero di feature di input, abilitando computazioni più efficienti nello spazio delle feature potenziato quantisticamente.

L'architettura della QNL-Net è un **modello ibrido classico-quantistico**. Include una fase di **pre-elaborazione classica** per la riduzione della dimensionalità dei dati di input. In questo studio, vengono impiegate tecniche classiche come le **CNN** o l'**Analisi delle Componenti Principali (PCA)** per questo scopo. Queste tecniche riducono i dati di input originali a un **vettore di feature di dimensione 4x1**, adatto per l'elaborazione da parte del modulo QNL-Net.

Il **cuore quantistico** della QNL-Net **1** è un **circuito a 4 qubit** composto da tre parti: un **Encoder** per trasformare i dati classici in stati quantistici, un **Variational Quantum Circuit (VQC)** addestrabile e una fase di **Misurazione**. L'Encoder utilizza un layer di porte di Hadamard e porte Phase con parametri addestrabili per codificare i dati classici.

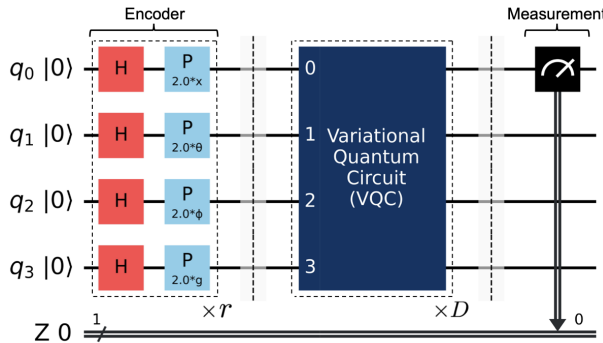


Figure 1: Circuito quantistico della QNL-Net

Il **VQC** è cruciale e utilizza una combinazione di

porte di rotazione (R_x , R_y , R_z) con parametri addestrabili e **porte CX (CNOT)** **2**. Le porte di rotazione manipolano lo stato quantistico, facilitando trasformazioni spaziali per catturare intricate dipendenze. Le **porte CX** stabiliscono **correlazioni indotte dall'entanglement** tra i qubit, fondamentali per catturare le dipendenze non locali. Vengono esplorate tre configurazioni distinte di entanglement per le porte CX, chiamate Ansatz-0, Ansatz-1 e Ansatz-2. Ogni strato del VQC consiste di 5 parametri e può essere ripetuto D volte per aumentare l'espressività del modello.

La misurazione finale del circuito quantistico avviene nella **base Pauli-Z**, specificamente sul **qubit 0**. La misurazione di un osservabile (\hat{O}) per uno stato $|\psi\rangle$ è data dal suo valore di aspettazione $\langle\hat{O}\rangle = \langle\psi|\hat{O}|\psi\rangle$. In questo caso, la misurazione sul qubit 0 è $\langle Z\rangle = \langle\psi_s|U^\dagger(\theta)Z_{q0}U(\theta)|\psi_s\rangle$.

Dopo la misurazione del QNL-Net, viene eseguito un **ulteriore calcolo classico**. Questo include un **strato completamente connesso (FC)** con un singolo parametro addestrabile per ottimizzare e affinare l'output quantistico, migliorando il processo di classificazione binaria.

3 Implementazione Personale

Per la mia implementazione personale, ho deciso di replicare il modello **CNN-QNL-Net** per la **classificazione binaria** tra le classi **2 (uccelli)** e **8 (navi)** del dataset **CIFAR-10**. Successivamente, ho esteso il modello per affrontare un problema di **classificazione multiclasse a 4 classi**, utilizzando sia le classi **0, 1, 2, 3** del dataset **MNIST**, sia le classi **0 (aeroplani)**, **1 (automobili)**, **2 (uccelli)** e **8 (navi)** del dataset **CIFAR-10**.

Tutte le implementazioni sono state realizzate utilizzando la libreria **qiskit** e allenate tramite simulazione quantistica, sfruttando il simulatore fornito dalla stessa piattaforma. Il codice completo è disponibile su [GitHub](#).

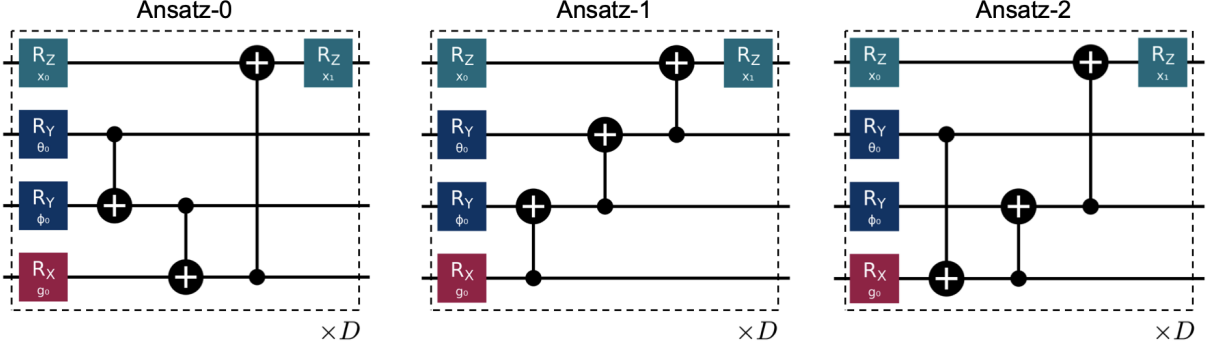


Figure 2: I tre ansatz utilizzati come circuiti quantistici variazionali (VQC) nel meccanismo QNL-Net. Le porte di rotazione R_x , R_y , R_z rappresentano rotazioni su un singolo qubit lungo gli assi x , y , e z , rispettivamente, con parametri addestrabili. Le strategie di entanglement basate su porte CX (CNOT) includono: pattern ciclico (Ansatz-0), catena lineare inversa (Ansatz-1) e pattern misto (Ansatz-2).

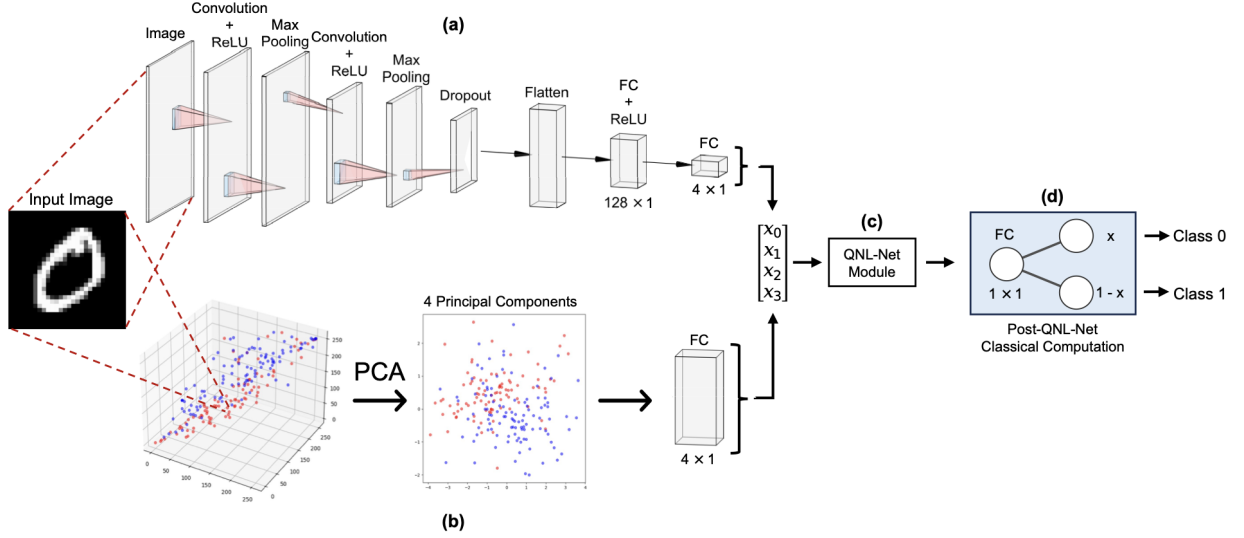


Figure 3: Architettura del framework ibrido quantistico-classico QNL-Net. (a) **CNN-QNL-Net**: due strati convoluzionali con attivazione ReLU e max-pooling estraggono le feature dalle immagini in input, seguiti da dropout, flattening e due strati completamente connessi (FC) per il pre-processing. (b) **PCA-QNL-Net**: la PCA riduce la dimensionalità a 4 componenti, che vengono elaborate tramite uno strato FC prima di essere inviate alla QNL-Net. (c) **QNL-Net**: esegue operazioni sui quattro attributi classici e produce una misura dal qubit 0. (d) **Computazione classica post-QNL-Net**: uno strato FC affina l'output quantistico, che viene poi trasformato e concatenato per la classificazione binaria.

3.1 Dettagli dell'implementazione multiclasse

L'estensione del modello alla classificazione multiclasse ha richiesto modifiche minime rispetto al design originale. In particolare:

- **Circuito quantistico:** invece di misurare soltanto il qubit 0, vengono misurati anche i risultati del qubit 1, entrambi nella base Z (Pauli-Z). In questo modo è possibile ottenere 4 combinazioni di output (00, 01, 10, 11), che permettono di rappresentare 4 classi distinte utilizzando 2 qubit.
- **Layer classico post-QNL-Net:** è stato adattato da uno strato fully connected con 1 input e 2 output (usato nella classificazione binaria) a uno strato con 2 input e 4 output, per tradurre correttamente le misure quantistiche nei corrispondenti output di classificazione.

Queste due semplici modifiche si sono rivelate efficaci per il dataset **MNIST**, dove il modello ha ottenuto risultati promettenti pur mantenendo una struttura semplice e coerente con l'architettura originale. Tuttavia, lo stesso approccio non ha prodotto prestazioni soddisfacenti sul dataset **CIFAR-10**, suggerendo che quest'ultimo potrebbe richiedere una soluzione più sofisticata o un modello più profondo per ottenere risultati comparabili.

4 Valutazione Sperimentale e Risultati

4.1 Classificazione Binaria su CIFAR-10

Per la valutazione sperimentale, ho allenato il modello **CNN-QNL-Net** utilizzando l'**Ansatz 1** con una singola ripetizione, per un totale di **10 epoche**. I risultati ottenuti sono in linea con quelli riportati nel paper originale, con una **accuratezza sul training set pari a 0.9317** e una **accuratezza sul test set pari a 0.9405**.

La curva della training loss riportata in Figura 4 mostra che il modello non sembra aver ancora raggiunto la convergenza. Questo suggerisce che un numero maggiore di epoche di allenamento potrebbe portare a ulteriori miglioramenti delle prestazioni. Tuttavia, tale estensione non è stata effettuata a causa di vincoli computazionali.



Figure 4: Curva della training loss durante l'allenamento del modello su CIFAR-10.

4.2 Classificazione Multiclasse su MNIST

Per la valutazione sperimentale, ho allenato il modello **CNN-QNL-Net**, opportunamente modificato per la classificazione multiclasse a 4 classi (come descritto nella sezione precedente), utilizzando l'**Ansatz 0** con una singola ripetizione e un totale di **10 epoche**.

I risultati ottenuti sono molto positivi, con una **accuratezza sul training set pari a 0.9868** e una **accuratezza sul test set pari a 0.9930**. Anche in questo caso, la curva della training loss riportata in Figura 5 indica che il modello non ha ancora raggiunto la convergenza. Ciò suggerisce che un allenamento prolungato potrebbe ulteriormente migliorare le prestazioni.

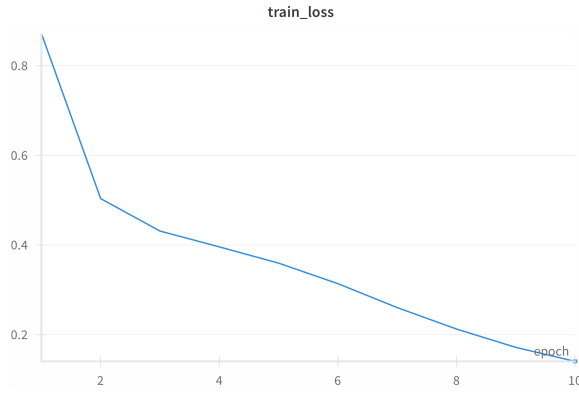


Figure 5: Curva della training loss durante l'allenamento del modello su MNIST.

4.3 Classificazione Multiclasse su CIFAR-10

Per questo esperimento, ho utilizzato l'**Ansatz 1** con una singola ripetizione del circuito variazionale. I risultati ottenuti sono stati purtroppo deludenti, con una **accuratezza sul training set pari a 0.7097** e una **accuratezza sul test set di 0.5563**, a indicare una scarsa capacità di generalizzazione del modello.

Ho provato anche configurazioni con un numero maggiore di ripetizioni dell'Ansatz, nella speranza che una capacità espressiva aumentata potesse migliorare le prestazioni. Tuttavia, **i risultati sono rimasti scadenti** anche in questi casi.

Questi esperimenti hanno confermato quanto già suggerito dalla letteratura: la generalizzazione dei modelli ibridi quantistici a compiti di classificazione multiclasse su dataset più complessi, come CIFAR-10, richiede probabilmente soluzioni architetturali più sofisticate o approcci di encoding differenti.

5 Discussione

La QNL-Net sfrutta l'**entanglement quantistico come vantaggio chiave**. Mentre i blocchi non locali classici coinvolgono moltiplicazioni matriciali, la QNL-Net utilizza gli **entanglements CX per replicare le dipendenze variabili** presenti nei

meccanismi non locali classici. Questo favorisce un sistema altamente interconnesso tra tutti i qubit, estraendo efficacemente probabilità intricate ed esplorando strutture di dati complesse in un framework quantistico.

L'applicazione aggiuntiva di porte di rotazione (come Rz sul qubit 0) introduce una **modulazione di fase essenziale** all'interno del sistema entangled, cruciale per ottimizzare lo stato quantistico prima della misurazione e influenzare la probabilità di un outcome. La specifica configurazione dell'entanglement (Ansatz-0, -1, -2) sembra meno cruciale rispetto all'entanglement di tutti i qubit con diverse rotazioni.

6 Limitazioni e Direzioni Future

Nonostante i risultati promettenti, si possono identificare alcune **limitazioni** dell'approccio attuale. L'implementazione proposta **fa ancora affidamento su metodi classici di pre-elaborazione e supporto**, che possono diventare computazionalmente inefficienti nel caso di dataset di grandi dimensioni o modelli più complessi. Tale compromesso è stato adottato per ridurre il numero di risorse quantistiche necessarie.

Come evidenziato anche nel paper originale, l'estensione del modello alla **classificazione multiclasse** non è banale. Raggiungere risultati soddisfacenti su MNIST ha richiesto un'attenta progettazione, mentre è stato **impossibile ottenere prestazioni comparabili su CIFAR-10** senza alterare significativamente l'architettura proposta.

Gli autori del lavoro originale suggeriscono diverse **direzioni per sviluppi futuri**, tra cui:

- la validazione del modello su **dataset più ampi e diversificati**,
- l'esplorazione di **strategie alternative di codifica quantistica**,
- lo studio di **nuovi design per i circuiti variazionali (VQC)**, con l'obiettivo di migliorarne la capacità espressiva e la generalizzazione.

Questi sviluppi potrebbero contribuire a migliorare la scalabilità e l'efficacia dei modelli ibridi quantistico-classici in contesti reali e su problemi di classificazione più complessi.

7 Conclusione

Questo lavoro ha presentato il framework **Quantum Non-local Neural Network (QNL-Net)** come un **approccio ibrido classico-quantistico** innovativo per la classificazione di immagini. È stata fornita un'implementazione del modello, accompagnata da un tentativo di estensione alla classificazione multi-classe.

Gli esperimenti condotti sui dataset **MNIST** e **CIFAR-10** hanno dimostrato che i modelli QNL-Net proposti offrono **prestazioni competitive nella classificazione binaria**, utilizzando **meno qubit** rispetto ai classificatori quantistici convenzionali. Tuttavia, il passaggio alla **classificazione multi-classe** risulta più complesso e ha evidenziato **limiti di scalabilità** dell'architettura attuale, in particolare su dataset più complessi come CIFAR-10.

Questi risultati sottolineano il potenziale dei modelli ibridi quantistici, ma anche la necessità di ulteriori studi per migliorarne la generalizzazione e l'adattabilità a compiti di classificazione più articolati.